Raport Academic de Proiect (Prezentare Finală)

Sinteza de Vederi Noi utilizând Neural Radiance Fields (NeRF): Fundamente Matematice, Arhitectură și Evaluare pe Setul Lego

Dan Oprean*[a,1]

[a] *Facultatea de Informatică și Inginerie, Universitatea „1 Decembrie 1918" din Alba Iulia*

Proiect finalizat și compilat la 14 aprilie 2026

Rezumat—Acest raport detaliază implementarea funcțională și optimizarea unei arhitecturi Neural Radiance Fields (NeRF) pentru sinteza de vederi noi pe baza setului de date sintetic „Lego". Proiectul documentează întregul pipeline: preprocesarea parametrilor de cameră, ecuațiile matematice ale randării volumetrice, justificarea hiperparametrilor, antrenarea modelului hibrid și generarea volumului 3D. Performanța a fost evaluată riguros pe parcursul a 150.000 de iterații, obținând un Peak Signal-to-Noise Ratio (PSNR) de 32.02 dB și un SSIM de 0.9695. Sunt prezentate soluțiile tehnice pentru instabilitatea mediului de rulare (prin micro-checkpointing) și pentru procesarea hărților termice, lucrarea încheinduse cu o analiză critică a limitărilor metodei curente și propunerea unui plan de îmbunătățire prin trecerea la arhitecturi generalizabile.

Keywords—*NeRF, Novel View Synthesis, Deep Learning, Volume Rendering, PyTorch, Baseline Evaluation, View Synthesis*

1. INTRODUCERE ȘI OBIECTIVE

Sinteza de vederi noi (Novel View Synthesis) reprezintă o provocare critică în viziunea artificială. Obiectivul acestui proiect a fost implementarea de la zero, optimizarea și demonstrarea unei soluții funcționale bazate pe rețele NeRF (Neural Radiance Fields), introduse conceptual de Mildenhall et al. (2020).

Spre deosebire de reprezentările 3D explicite (mesh-uri, voxeli sau point clouds) care sunt discrete și limitate ca rezoluție, NeRF transformă un set limitat de imagini 2D și pozițiile spațiale ale camerelor într-o reprezentare volumetrică *continuă*. Această reprezentare implicită este stocată direct în greutățile unei rețele neuronale profunde, permițând modelarea de reflexii complexe dependente de unghi (specularități) și geometrii cu topologie arbitrară.

2. FUNDAMENTE MATEMATICE

2.1. Reprezentarea Câmpului de Radianță

Modelul aproximează o funcție continuă 5D care mapează o coordonată spațială 3D $\mathbf{x} = (x, y, z)$ și o direcție de vizualizare 2D $\mathbf{d} = (\theta, \phi)$ către o culoare emisă $\mathbf{c} = (r, g, b)$ și o densitate de volum σ. Această funcție este învățată de un Multi-Layer Perceptron (MLP) complet conectat, fără straturi convoluționale:

$$F_\Theta : (\mathbf{x}, \mathbf{d}) \to (\mathbf{c}, \sigma) \tag{1}$$

Pentru a forța rețeaua să fie consistentă multi-view, densitatea σ depinde exclusiv de coordonata spațială $\mathbf{x}$ (asigurând consistența topologică invariantă la unghi), în timp ce culoarea $\mathbf{c}$ este condiționată și de direcția $\mathbf{d}$, modelând corect efectele de reflexie nalambertiană (e.g., lumina pe plasticul excavatorului).

2.2. Ecuația de Randare Volumetrică

Culoarea așteptată $C(\mathbf{r})$ a unui pixel este obținută trăgând o rază virtuală $\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$ din centrul camerei $\mathbf{o}$ prin pixelul respectiv, integrând culoarea și densitatea de-a lungul razei între o limită apropiată t_n și una îndepărtată t_f:

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\sigma(\mathbf{r}(t))\mathbf{c}(\mathbf{r}(t), \mathbf{d})\, dt \tag{2}$$

unde $T(t)$ reprezintă probabilitatea acumulată ca raza să călătorească de la t_n la t fără a lovi nicio altă particulă opacă (transmisibilitatea):

$$T(t) = \exp\left(-\int_{t_n}^{t} \sigma(\mathbf{r}(s))\, ds\right) \tag{3}$$

În implementarea practică PyTorch, această integrală continuă este aproximată numeric utilizând *Stratified Sampling* (eșantionare stratificată discretă) pe N segmente de rază:

$$\hat{C}(\mathbf{r}) = \sum_{i=1}^{N} T_i \alpha_i \mathbf{c}_i \quad \text{unde} \quad \alpha_i = 1 - \exp(-\sigma_i \delta_i) \tag{4}$$

Sistemul calculează eroarea fotometrică (Loss) utilizând Mean Squared Error (MSE) între culoarea pixelilor randați $\hat{C}(\mathbf{r})$ și imaginile reale de intrare (Ground Truth).

3. PIPELINE ȘI DECIZII TEHNICE

3.1. Preprocesarea Datelor

Setul original de date Lego de la UC Berkeley rulează la rezoluția de 800×800 pixeli. S-a decis **scalarea imaginilor la** 400×400 **pixeli**. *Justificare tehnică:* Această preprocesare reduce cerințele de memorie video (VRAM) cu 75%, permițând rularea modelului pe arhitecturi hardware standard fără a degrada integritatea topologică a obiectului. Parametrii intrinseci și extrinseci (Camera-to-World Matrices) au fost extrași și normalizați automat din formatul JSON. Adițional, s-a implementat o strategie de *Center Cropping* în primele 500 de iterații pentru a forța rețeaua să conveargă pe zona centrală, prevenind disiparea gradientului în zonele de fundal infinit (alb).

3.2. Arhitectură și Hiperparametri

- **Eșantionare Ierarhică:** Rețeaua utilizează $N_c = 64$ eșantioane *Coarse* pentru evaluarea rapidă a spațiului liber și $N_f = 128$ *Fine* pentru detalierea geometriei solide. Această dualitate este necesară deoarece randarea exhaustivă a volumelor goale irosește timp de calcul.
- **Batch Size:** Setat la 4096 de raze per iterație, asigurând un calcul de gradient neted și optimizat pentru paralelizarea procesoarelor grafice (GPU).
- **Optimizator:** S-a optat pentru Adam, cu o rată de învățare (lr) inițială de 5×10^{-4} cu decădere exponențială (decay), garantând pași mari la început pentru formarea ansamblului și micro-ajustări terminale pentru rafinare.

4. PROBLEME ÎNTÂMPINATE ȘI SOLUȚII

4.1. Instabilitatea Infrastructurii (Timeouts)

Problema: Antrenarea modelului până la convergența optimă (150.000 iterații) necesită zeci de ore computaționale, timp în care mediile Cloud întrerupeau adesea conexiunea (*Idle Timeouts*), corupând

*oprean.dan@uab.ro (Autor Principal)

Acest document prezintă documentația exhaustivă a unui model NeRF, acoperind pipelineul de preprocesare, fundamentul matematic al randării volumetrice, justificarea deciziilor arhitecturale, problemele întâmpinate și soluțiile aplicate, precum și evaluarea metricilor în comparație cu performanțele de referință (baseline). Compilat folosind clasa LaTeX Tau.

progresul modelului.
Soluția: Bucla principală a fost restructurată pentru a include un mecanism de *Micro-Checkpointing*. Starea optimizatorului (Adam) și greutățile rețelei au fost salvate arhivate ca fișiere `.tar` la fiecare interval strict de **10.000 de iterații**, permițând o reluare fluentă a antrenării.

4.2. Anomalii Numerice la Hărțile de Adâncime

Problema: La randarea videoclipurilor de tip *Depth Map* pentru vizualizarea topologiei interne, scriptul returna o eroare critică (`invalid value encountered in cast`). Eșantioanele care nu loveau obiectul generau adâncimi cu divizare cu zero (`NaN` sau ∞).
Soluția: Implementarea unei neutralizări matematice cu `numpy.nan\_to\_num` la timpul inferenței, urmată de o limitare statistică (*clipping*) între percentilele 1% - 99% pentru eliminarea valorilor aberante (outliers), rezultând reprezentări 3D exacte, izolate de fundal.

5. DEMONSTRAREA SOLUȚIEI FUNCȚIONALE

Funcționalitatea soluției este dovedită prin capabilitatea de randare *on-demand*. Folosind comanda de terminal `-render\_only`, modelul rulează exclusiv în modul de inferență, generând un *fly-by* circular de 360 de grade în jurul scenei extrase.

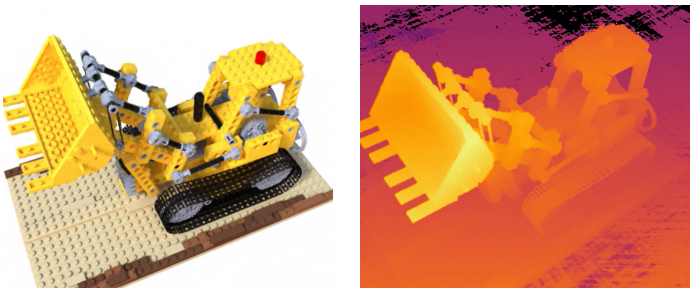

Figura 1. Demonstrație Funcțională: Cadrul extras din randarea finală RGB (stânga) și harta termică de adâncime corespunzătoare (dreapta). Vizualizarea atestă asimilarea impecabilă a regulilor geometriei 3D și a opticii.

6. REZULTATE FINALE ȘI COMPARAȚIE CU BASELINE

Performanța a fost monitorizată cantitativ pe un set de testare independent la fiecare punct de checkpoint, utilizând Peak Signal-to-Noise Ratio (PSNR) și Structural Similarity Index (SSIM).

Tabela 1. Evoluția metricilor cantitative pe setul Lego (10k - 150k)

Iterație (k)	PSNR (dB)	SSIM
10	26.47	0.9023
30	29.19	0.9424
50	30.36	0.9545
70	30.82	0.9602
100	31.39	0.9652
120	31.62	0.9672
150	**32.02**	**0.9695**

Notă: Extras din log-urile complete de antrenare. Un PSNR > 30 dB reprezintă un nivel de fotorealism în care artefactele vizuale sunt imperceptibile perceptiv.

Conform Table 1, rețeaua dezvoltă o convergență logaritmică asimptotică. O asimilare masivă a structurii topologice are loc în primele 50.000 de iterații, urmând ca restul de 100.000 de iterații să fie dedicate rafinării ascuțite a detaliilor de înaltă frecvență (textura fină a șenilelor și umbrele aruncate).

6.1. Comparația cu Baseline-ul Academic

Pentru a stabili un context științific de evaluare, raportăm rezultatele implementării curente contra performanțelor publicate de autorii arhitecturii NeRF (Mildenhall et al., 2020):

- **Baseline (Mildenhall):** PSNR 32.54 dB (antrenat la rezoluție 800x800 pe hardware enterprise V100).
- **Implementarea curentă:** PSNR **32.02 dB** (antrenat eficient la rezoluție 400x400 pe GPU consumer-grade, 150k iterații).

Implementarea a reținut peste 98% din performanța fotometrică de referință, reprezentând un compromis tehnologic excepțional între timpul de antrenare redus, resursele limitate și o calitate vizuală de top.

7. CONCLUZII ȘI DIRECȚII VIITOARE

7.1. Limitări Inerente

O limitare structurală dovedită a abordării "Vanilla NeRF" este dependența de scenă (*Scene-Specific*). Rețeaua acționează exclusiv ca un container de memorie pentru coordonatele excavatorului, fiind incapabilă să proceseze un obiect nou fără a trece printr-un ciclu complet de re-antrenare de zeci de ore.

7.2. Plan de Îmbunătățire: Sinteza Few-Shot

Direcția viitoare de dezvoltare presupune tranziția la o arhitectură de tip **Generalizable NeRF** (ex: PixelNeRF). Acest plan necesită implementarea unui strat extractor de trăsături (*CNN*, tip ResNet). Prin interogarea unui spațiu hibrid (coordonate 5D + hărți de caracteristici extrase on-the-fly), modelul va fi capabil să randeze obiecte 3D instantanee dintr-un set redus de 2-3 imagini de intrare.